

MediTrack

Gabriel Batista de Oliveira Vilas Boas - 2024000467

Gabriel Del Monte Schiavi Noda - 2022014552

Gabrielle Gomes Almeida - 2022002758

IESTI05 - Machine Learning Systems Engineering

1 Introdução

Este trabalho apresenta o desenvolvimento de um sistema embarcado baseado em visão computacional para auxiliar idosos no uso correto de medicamentos. Utilizando uma Raspberry Pi Zero 2 W e uma câmera, o sistema aplica técnicas de classificação e detecção de imagens para reconhecer os remédios manuseados pelo usuário.

A proposta busca oferecer uma solução acessível e eficiente que reduza erros na rotina de medicação, promovendo maior autonomia e segurança ao paciente por meio da integração entre hardware compacto e modelos de aprendizado de máquina otimizados.

2 Declaração do problema e motivação

Com o avanço da idade, o surgimento de problemas cognitivos e motores pode influenciar no bem-estar de qualquer pessoa, seja em tarefas complicadas do trabalho ou rotinas simples no dia-a-dia. Problemas de memória, fraqueza, perda de flexibilidade nas mãos, etc., são apenas alguns exemplos de problemas que são enfrentados por idosos todos os dias, dificultando sua vida em questões pertinentes, como o cuidado com a saúde pessoal.

O envelhecimento é inevitável, e com ele chega também a necessidade do uso de medicamentos e coquetéis que auxiliem no combate aos problemas inerentes à idade. Entretanto, estas mesmas dificuldades tornam-se obstáculos para aqueles que precisam se medicar constantemente, fazendo-se necessário o desenvolvimento de alguma ferramenta que visa facilitar a vida pessoal destes indivíduos.

Portanto, é nessa dificuldade que o trabalho se baseia, a fim de oferecer um meio para que idosos possam seguir sua rotina de medicação com menos esforço, possivelmente reduzindo erros durante o tratamento e, com isso, reduzindo os riscos de saúde oferecidos pelo uso inadequado de medicamentos.

3 Revisão da literatura e trabalhos relacionados

Como fundamentação teórica, o trabalho se baseia no artigo de Marília Cruz Guttier, *"Dificuldades no uso de medicamentos por idosos acompanhados em uma coorte do Sul do Brasil"*, que levantou dados sobre o tema com uma amostra de idosos no país.

Segundo o estudo, cerca de 15,5% dos idosos acompanhados necessitavam de ajuda para utilizar seus medicamentos na dose e horários corretos, sendo que quanto maior a idade e menos a escolaridade, maior foi a proporção de idosos que referiram necessidade de ajuda. Além disso, outro estudo realizado em unidades básicas de saúde no estado de São Paulo, observou que 46,8% dos idosos não conseguem tomar seus medicamentos nas doses e horários corretos. A

polifarmácia (uso de quatro ou mais medicamentos simultaneamente) também foi apontada como agravante do problema, devido à dificuldade que os idosos podem ter de escolher quais os medicamentos corretos que devem ser tomados em cada horário.

4 Proposta de Solução e Fundamentação Técnica

Com base nas dificuldades apontadas na literatura sobre o uso de medicamentos por idosos, como esquecimentos, confusões entre remédios e dificuldades motoras, este trabalho propõe o desenvolvimento de um sistema embarcado baseado em visão computacional, capaz de auxiliar no controle da medicação e reduzir erros durante o tratamento.

O principal objetivo do sistema é identificar qual medicamento o idoso pegou em sua mão, utilizando técnicas de **classificação** e **detecção de imagens**. Em versões futuras, o sistema poderá evoluir para monitorar também se o remédio foi ingerido e registrar automaticamente o horário e a imagem da ação em uma planilha no *Google Sheets*, permitindo o acompanhamento remoto.

A implementação utiliza o dispositivo *Raspberry Pi Zero 2 W*, acoplado a uma câmera responsável pela captura e processamento local das imagens. Devido às limitações de processamento desse hardware, o foco do projeto é a etapa de **detecção dos remédios**, visando validar a capacidade do modelo em reconhecer e detectar corretamente o medicamento segurado pelo idoso.

5 Classificação de Imagens

5.1 Descrição e processo de preparação dos dados

Para a pesquisa, foi utilizado um dataset dedicado à classificação de imagens, composto por cinco classes. Dentre elas, uma corresponde ao "background", e as outras quatro são de medicamentos específicos selecionados para a classificação: *Ambroxol*, *Cefalexina*, *Ferro* e *Sany D*. Cada classe foi organizada de modo que as imagens de cada categoria contivessem exclusivamente um único tipo de medicamento. As imagens incluem somente a caixa do medicamento. A escolha de implementar inicialmente um modelo de classificação de imagens foi feita para testar e validar a capacidade do sistema em diferenciar entre as classes, antes de avançar para a fase de detecção de objetos.

As imagens foram capturadas com a câmera da *Raspberry Pi Zero 2 W*, utilizando dois tipos de fundo distintos: preto e com estampas. Essa variação de fundo teve como objetivo simular cenários variados e aumentar a robustez do modelo, permitindo que ele aprendesse a identificar os medicamentos independentemente do ambiente de fundo. Além disso, a diversidade de fundos ajuda a evitar que o modelo dependa excessivamente de elementos de fundo específicos, tornando-o mais generalista e capaz de lidar com diferentes condições de iluminação e posicionamento. As imagens foram registradas com iluminação artificial e ângulos variados para garantir uma boa diversidade de dados e melhorar o desempenho do modelo em situações reais. O dataset de classificação passou apenas pelo processo de *Resize mode*.

5.2 Arquitetura do modelo

O modelo de classificação foi desenvolvido utilizando a técnica de transfer learning com a arquitetura **MobileNetV2 160x160 1.0**. Após o treinamento, o modelo foi exportado para

o formato **TensorFlow Lite (float32)** para deployment, e uma versão **quantizada (int8)** também foi gerada.

5.3 Metodologia de treinamento

- **Coleta e preparação dos dados:**
Imagens rotuladas por classe e organizadas em diretórios. Realizou-se também a limpeza dos dados e o balanceamento inicial das classes;
- **Pré-processamento:**
Redimensionamento para 160×160 , conversão para o formato RGB e normalização dos valores dos pixels;
- **Aumento de dados (Data Augmentation):**
Não foi realizado, optando-se por utilizar os dados originais;
- **Particionamento dos dados:**
Divisão dos dados em subconjuntos de treino e teste na proporção 80/20, garantindo uma distribuição equilibrada das classes em ambos os conjuntos;
- **Configurações de treinamento:**
O modelo foi treinado por 30 épocas, com taxa de aprendizado (learning rate) de 0.05.

5.4 Avaliação e análise de desempenho

O modelo treinado na plataforma *Edge Impulse* apresentou uma acurácia de 97.1% e uma perda de apenas 0.9%, o que o classifica como um modelo eficiente no que ele se propõe a fazer. Durante a avaliação, o modelo cometeu um único erro de classificação, identificando erroneamente o medicamento *Cefalexina* como *Sany D*.

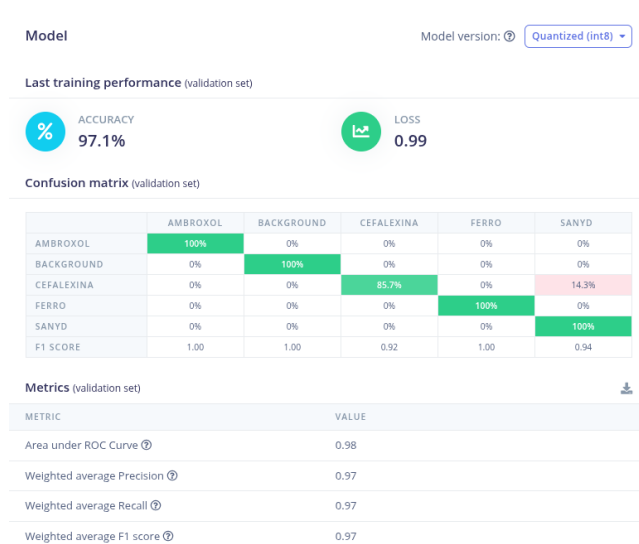


Figura 1: Gráfico de desempenho do modelo de classificação no *Edge Impulse*.

5.4.1 Análise de desempenho no ambiente do Jupyter Notebook

Ao testar o modelo *float32* no ambiente do *Jupyter Notebook*, utilizando imagens do próprio dataset e imagens externas (tiradas em condições ambientais diferentes), o modelo manteve um desempenho consistente. Para as imagens presentes no dataset, a precisão continuou alta, com o modelo obtendo 100% de probabilidade de acerto para as novas imagens. As imagens externas, apesar de possuírem variações nas condições de captura, também foram classificadas com precisão, sem erros detectados. O tempo de inferência foi, em média, de 100 *ms*, o que demonstra a rapidez e eficiência do modelo em termos de tempo de resposta.

```
[PREDICTION]      [Prob]
ferro              : 100.0%
sany_d            : 0.0%
cefalexina        : 0.0%
background        : 0.0%
ambroxol          : 0.0%

Inference time: 100.7ms
```



Figura 2: Classificação correta da classe "ferro", presente no dataset

```
[PREDICTION]      [Prob]
cefalexina        : 100.0%
sany_d            : 0.0%
ferro             : 0.0%
background        : 0.0%
ambroxol          : 0.0%

Inference time: 101.2ms
```



Figura 3: Classificação correta da classe "cefalexina"

5.4.2 Análise de desempenho em tempo real

Em um cenário de inferência em tempo real, embora o modelo tenha mostrado um tempo de estabilização um pouco mais longo inicialmente, ele foi capaz de classificar corretamente

80% das imagens em tempo real. A classe *"ambroxol"* foi a que apresentou maior taxa de erro, indicando uma possível área de melhoria, especialmente em condições variáveis de captura ou em situações em que a imagem está menos definida. Em geral, o modelo demonstrou um bom equilíbrio entre precisão, tempo de inferência e estabilidade, com áreas específicas para ajustes, como o aprimoramento da classificação da classe *"ambroxol"* em ambientes dinâmicos.




Figura 4: Classificação em tempo real da classe *"ferro"*




Figura 5: Classificação em tempo real da classe *"cefalexina"*

5.5 Pesquisas e adições futuras

Uma possível pesquisa futura seria o desenvolvimento de um sistema de feedback em tempo real capaz de monitorar as previsões do modelo de classificação e ajustar automaticamente parâmetros críticos, como a iluminação e o foco da câmera. Esse sistema teria a capacidade de adaptar-se às condições variáveis do ambiente durante o processo de inferência, permitindo que o modelo continue a operar com alta precisão, independentemente das mudanças nas condições de captura. A ideia é criar uma solução autônoma que, ao detectar uma diminuição na qualidade da imagem ou erro nas previsões, possa realizar ajustes sem intervenção humana.

Esse sistema de feedback em tempo real poderia melhorar significativamente a robustez e eficiência do modelo, especialmente em cenários imprevisíveis. Esse aprimoramento não só minimizaria a necessidade de ajustes manuais, mas também permitiria que o modelo operasse

de forma mais autossuficiente e eficaz, lidando melhor com diferentes condições de iluminação e outros desafios ambientais.

6 Detecção de Objetos

6.1 Descrição e Processo de Preparação dos Dados

Para a tarefa de detecção de objetos, foi utilizado um dataset contendo cinco classes. Diferentemente do dataset usado para classificação, neste caso, uma mesma imagem pode conter múltiplas classes simultaneamente. As imagens foram capturadas com a câmera da Raspberry Pi Zero 2 W, utilizando dois fundos distintos, preto e estampado, e sob iluminação artificial constante. O conjunto de dados foi carregado na plataforma Roboflow para a criação das bounding boxes e aplicação do pré-processamento. As etapas realizadas no pré-processamento vão ser citadas na seção "*Metodologia de treinamento*".

Após o pré-processamento, o dataset, contendo as imagens, anotações e classes, foi dividido em conjuntos de treino, teste e validação. Em seguida, o conjunto de dados foi importado para a plataforma Edge Impulse, onde o modelo final de detecção de objetos foi treinado.

6.2 Arquitetura do Modelo

O modelo de detecção de objetos foi desenvolvido utilizando a técnica de *transfer learning*, com base em um modelo pré-treinado disponível na plataforma Edge Impulse. A opção pela arquitetura **MobileNetV2 SSD FPN-Lite 320x320** foi feita em contraste com o modelo **YOLOv8**, pois, apesar de o YOLOv8 apresentar alta precisão em tarefas de detecção de objetos, ele não é totalmente compatível com as restrições de dispositivos embarcados e os requisitos de otimização para aplicações em tempo real. Por sua leveza e eficiência, o MobileNetV2 mostrou-se mais adequado para o contexto deste trabalho.

Após o treinamento com os dados personalizados, o modelo foi exportado no formato **TensorFlow Lite (float32)** para fins de *deployment*. Adicionalmente, foi gerada uma versão **quantizada (int8)** com o objetivo de otimizar o desempenho em dispositivos embarcados.

6.3 Metodologia de treinamento

- **Coleta e preparação dos dados:**

As imagens foram capturadas com a câmera da Raspberry Pi Zero 2 W, contendo múltiplos objetos por imagem. O processo de anotação foi realizado na plataforma Roboflow, utilizando *bounding boxes* para delimitação dos objetos e atribuição das respectivas classes. Posteriormente, foi feita uma verificação manual para garantir a consistência das anotações;

- **Pré-processamento:**

As imagens foram redimensionadas para 320×320 pixels com estiramento (*stretch to 320×320*), convertidas para o formato RGB e submetidas à correção automática de orientação (*auto-orient*). Também foi aplicado ajuste automático de contraste utilizando a técnica de *contrast stretching*.

- **Aumento de dados (Data Augmentation):**

Com o objetivo de aumentar a robustez do modelo, foram aplicadas técnicas de au-

mentação durante o treinamento, gerando três variações por imagem original. As transformações utilizadas incluem:

- Espelhamento horizontal e vertical;
- Variações de saturação entre -25% e +25%;
- Variações de brilho entre -15% e +15%;
- Variações de exposição entre -10% e +10%.

Para cada imagem original, foram geradas três variações aumentadas.

- **Particionamento dos dados:**

O conjunto de dados foi dividido automaticamente pela plataforma Roboflow nos subconjuntos de treino, validação e teste, respeitando a proporção aproximada de 80/10/10. As classes foram balanceadas entre os subconjuntos para garantir uma distribuição uniforme.

- **Configurações de treinamento:**

O modelo foi treinado na plataforma Edge Impulse utilizando a arquitetura **MobileNetV2 SSD FPN-Lite 320x320**. Foi aplicado *fine-tuning* sobre um modelo pré-treinado, com taxa de aprendizado fixa em 0.01 por 75 épocas. O tamanho do conjunto de treinamento foi representado por 80% do dataset original e o *batch size* utilizado foi de tamanho 16.

6.4 Avaliação e análise de desempenho

O modelo treinado para detecção de objetos na plataforma Edge Impulse obteve uma precisão de 80.0%, refletindo sua capacidade de identificar corretamente os objetos em imagens. Além disso, as métricas de desempenho indicam que o modelo possui um mAP@[IoU=50] de 0.80, o que demonstra um bom nível de precisão na detecção de objetos com uma sobreposição mínima de 50% entre a previsão e a bounding box real.

Durante a avaliação, o modelo cometeu alguns erros de classificação, mas conseguiu identificar corretamente a maioria dos objetos, com o recall@[max_detections=1] de 0.68, o que sugere que, na maioria dos casos, ele consegue detectar pelo menos um objeto relevante por imagem.

Model Model version: ① Unoptimized (float32) ▼

Last training performance (validation set)

% PRECISION SCORE ①
80.0%

Metrics (validation set) ⬇

METRIC	VALUE
mAP ①	0.62
mAP@[IoU=50] ①	0.80
mAP@[IoU=75] ①	0.76
mAP@[area=small] ①	-1.00
mAP@[area=medium] ①	0.63
mAP@[area=large] ①	0.61
Recall@[max_detections=1] ①	0.68
Recall@[max_detections=10] ①	0.70
Recall@[max_detections=100] ①	0.70
Recall@[area=small] ①	-1.00
Recall@[area=medium] ①	0.65
Recall@[area=large] ①	0.69

Figura 6: Gráfico de desempenho do modelo de detecção no *Edge Impulse*.

6.4.1 Análise de desempenho no ambiente Jupyter Notebook

Ao testar o modelo quantizado *int8* no ambiente do *Jupyter Notebook*, utilizando imagens do próprio dataset e imagens externas (tiradas em condições ambientais diferentes), o modelo manteve um desempenho consistente. Para as imagens presentes no dataset, a precisão continuou alta, com o modelo obtendo 100% de probabilidade de acerto para as novas imagens. As imagens externas, apesar de possuírem variações nas condições de captura, também foram detectadas com precisão média de 80%, sem erros detectados. O tempo de inferência foi, em média, de 500 *ms*.



Figura 7: Detecção em tempo real das classes "ferro" e "sany d"



Figura 8: Detecção em tempo real das classes "cefalexina" e "sany d"

6.4.2 Análise de desempenho em tempo real

Em um cenário de inferência em tempo real, embora o modelo tenha mostrado um tempo de estabilização um pouco mais longo inicialmente, ele foi capaz de classificar corretamente 70% das imagens em tempo real. Da mesma forma que o modelo de classificação, a classe "ambroxol" foi a que apresentou maior taxa de erro, indicando uma possível área de melhoria, especialmente em condições variáveis de captura ou em situações em que a imagem está menos definida. Em geral, o modelo demonstrou um bom equilíbrio entre precisão, tempo de inferência e estabilidade, com áreas específicas para ajustes, como o aprimoramento da classificação da classe "ambroxol" em ambientes dinâmicos.




Figura 9: Detecção da classe "ferro" em tempo real




Figura 10: Detecção da classe "ferro" e "sany d" em tempo real

6.5 Pesquisas e Adições Futuras

Como desdobramento deste trabalho, propõe-se a ampliação do sistema de reconhecimento de medicamentos, de modo que ele seja capaz não apenas de identificar o medicamento que o idoso segura em suas mãos, mas também de verificar a efetiva ingestão do mesmo, por meio da aplicação de técnicas de reconhecimento de ações e análise de sequência de imagens. Dessa forma, pretende-se implementar o envio automatizado de informações, como o nome do medicamento, o horário de uso e a imagem correspondente, para o *Google Sheets*, possibilitando o acompanhamento remoto por familiares ou profissionais de saúde.

Sugere-se, ainda, o desenvolvimento de um mecanismo de ajuste automático dos parâmetros de captura, como brilho, foco e contraste, de forma a tornar o sistema mais robusto frente às variações de ambiente. Com a adoção de dispositivos embarcados mais potentes, como a Raspberry Pi 5, será viável empregar arquiteturas de redes neurais mais complexas, como o *YOLOv8*, aprimorando a precisão e a velocidade de detecção. Tais aprimoramentos visam consolidar o sistema como uma solução assistiva confiável, eficiente e acessível ao apoio da rotina medicamentosa de pessoas idosas.

7 Desafios e soluções

O maior desafio enfrentado durante o desenvolvimento deste projeto foi a criação de um dataset robusto que permitisse distinguir claramente os medicamentos. Como todos os remédios possuem embalagens de formato similar, as principais diferenças entre eles se dão pelas cores e detalhes visuais das caixas. Isso tornou a tarefa de criar um dataset visualmente variado e capaz de treinar um modelo eficaz mais complexa.

Para contornar essa dificuldade, foi necessário adaptar as condições de captura das imagens. Foram testados diversos cenários de fundo (backgrounds) e fontes de iluminação para garantir que as imagens fossem nítidas e os medicamentos pudessem ser facilmente identificados pela câmera do dispositivo Raspberry Pi. Após diversas iterações, conseguimos encontrar uma configuração ideal que maximiza a clareza das imagens sem interferir nas características visuais dos remédios.

8 Referências

GUTTIER, Marília Cruz et al. Dificuldades no uso de medicamentos por idosos acompanhados em uma coorte do Sul do Brasil. *Revista Brasileira de Epidemiologia*, v. 26, p. e230020, 2023.